# PaleographIA: resumo e roteiro da apresentação

Nov 10, 2026 · @Rodolfo Vinicius Cima Takemoto.

## Resumo do programa

O PaleographIA é uma ferramenta aberta e gratuita que ajuda a transcrever manuscritos dos séculos XVII a XIX do Arquivo Histórico de Jundiaí: o modelo sugere a leitura de cada linha e uma pessoa confere na imagem e valida.

**O problema.** O acervo de Jundiaí está digitalizado e público, mas quase nada está transcrito. Ler essas páginas exige formação em paleografia: abreviaturas, grafias antigas, letras que mudam de forma. Arquivos de cidades pequenas não têm paleógrafos para isso.

**A ideia.** A máquina não substitui o leitor: ela adianta o trabalho. Nenhuma sugestão vira transcrição sem conferência humana. Saída do modelo, sugestão e transcrição validada ficam sempre separadas, com o nome de quem validou e o histórico de cada mudança.

**O caminho de uma página, do começo ao fim:**

1. **Imagem.** A página do acervo entra no aplicativo (com crédito ao Arquivo, uso acadêmico e não comercial autorizado).
2. **Linhas.** O Kraken (segmentador blla, uma rede neural) desenha cada linha de texto e recorta a imagem dela.
3. **Leitura do modelo.** O PP-OCRv6 medium, ajustado com páginas de Jundiaí, lê cada recorte e propõe o texto.
4. **Revisão humana.** No modo leitura, o revisor vê o recorte ampliado, o contexto das linhas vizinhas e a sugestão; corrige e aperta Enter para validar.
5. **Texto diplomático.** As linhas validadas formam a transcrição paleográfica: como está escrito, sem atualizar nada.
6. **Leitura modernizada.** Por cima da diplomática, o programa gera uma versão em português atual para quem só quer ler ou buscar, com as palavras duvidosas sublinhadas e notas de um glossário histórico.
7. **Métricas.** CER e WER comparam a leitura do modelo com a validada e medem o quanto cada versão do modelo melhorou.

## Como funciona por dentro

Cada parte do programa tem um papel e uma trava contra erro; vale saber explicar cada uma em uma frase.

| Parte | O que faz | Por que importa |
|---|---|---|
| Aplicativo (FastAPI, no navegador) | Editor completo, **modo leitura** para revisar e aba **Textos** para ler o resultado | Cada validação grava uma revisão nova com nome do revisor; nada é sobrescrito |
| Segmentação (Kraken blla) | Encontra as linhas da página e junta pedaços cortados | Recorte ruim pode ser ajustado, juntado ou rejeitado pelo revisor |
| Reconhecimento (PP-OCRv6 medium) | Rede pré-treinada em manuscritos históricos, roda no Docker | Partiu de 15% de CER no Traslado, contra 58% do PP-OCRv5 |
| Ajuste fino A e B | A: 191 linhas do Traslado. B: Traslado + 550 linhas públicas da Inquisição | Adaptação de domínio: o modelo aprende a letra e as grafias de Jundiaí |
| Ajustados C e D1 (Posturas de 1831) | Traslado + linhas das Posturas de 1831 validadas pela equipe. O D1 deixa o fólio 101r fora do treino e escolhe o melhor ponto nele | O D1 passou o B no teste reservado e é o modelo da aplicação desde 11/11 |
| Modo leitura | Recorte ampliado, setas para mover, contexto de 1 a 3 linhas acima e abaixo, Enter valida | Torna a revisão humana rápida, que é o gargalo real |
| Análise de erros (PLN) | Alinha leitura e referência por Levenshtein e classifica cada erro: espaço, pontuação, abreviatura, maiúscula, acento, grafia histórica, nome, forma da letra | Mostra o que o ajuste corrigiu (forma da letra, palavras coladas) e o que sobra (convenção de escrita) |
| Pós-correção lexical | Compara Levenshtein × TF-IDF de n-gramas de caracteres | Piorou o CER: o vocabulário de treino é pequeno. Fica só como sugestão ao revisor |
| Leitura modernizada v1 → v3 | Regras de grafia antiga → atual escolhidas pela frequência no português atual; a v2 trata caixa, nomes e pretérito; a v3 trata artigo, réis, futuro, hífen e palavras grudadas | Nunca altera a diplomática. Avaliada contra a edição modernizada do Arquivo |

| Parte | O que faz | Por que importa |
|---|---|---|
| Palavras a conferir e glossário | Sublinha o que ficou fora do dicionário atual; notas [1][2][3] explicam palavras antigas (magotes, rocio) | Mostra ao pesquisador onde a leitura é duvidosa e leva à linha certa |

**A trava mais importante: o teste reservado.** O pagamento a Thomas Pardo (1759) e um contrato de 1763 foram separados antes de qualquer treino, transcritos às cegas por dois integrantes com o reconhecedor desligado e congelados com hash. O código de treino recusa esses documentos, e cada modelo roda neles uma única vez. A validação, usada para escolher o melhor ponto do treino, são 7 linhas de uma sessão de 1795, de outra mão, e, desde o D1, também as 31 linhas do fólio 101r das Posturas, que ficam fora do treino.

## Números para citar

O ajuste fino baixa o erro em todas as medições, mas a generalização para mãos muito diferentes ainda é limitada. CER = erro por caractere, WER = erro por palavra; quanto menor, melhor.

| Medição | Antes | Depois | Observação |
|---|---|---|---|
| Escolha do modelo: fólio 269r do Traslado (24 linhas) | PP-OCRv5: CER 58,5% | PP-OCRv6: CER 15,1% | Por isso o v6 foi adotado |
| Validação: sessão de 1795 (7 linhas, outra mão) | Base: CER 14,2%, WER 56,7% | A: 10,7% / 41,8%; B: 10,1% / 38,8%; D1: 9,9% / 38,8% | A, B e D1 ficam a 1–3 caracteres um do outro, dentro da variação |
| Teste reservado, uma vez (49 linhas, duas mãos) | Base: CER 64,0% | A: 60,5%; B: 60,9%; D1: 55,4% | D1: 29% no pagamento (letra regular) e 66% no contrato (escrita densa), antes 74%. D1 − B: −8,1 a −3,3 pontos (IC 95%) |
| Modernização no contrato, contra a edição do Arquivo | Sem modernizar: WER 44,7% | v2: WER 30,5% | Avaliação fechada antes de olhar o resultado |
| Modernização nas Posturas de 1831 (75 linhas) | v2: WER 28,3% | v3: WER 21,2% | Linhas de desenvolvimento da v3 |

| Medição | Antes | Depois | Observação |
|---|---|---|---|
| Posturas, fólio 101r (31 linhas fora do treino) | B: CER 17,1% | D1: CER 15,7% | Base: 19,1%. Treinar com outro documento de Jundiaí ajuda |

Acurácia de caracteres ≈ 100% − CER: na validação, o D1 acerta cerca de 9 em cada 10 caracteres. Dados de treino do D1: 191 linhas do Traslado (175 alinhadas à edição publicada + 16 lidas pela equipe) e 63 linhas das Posturas de 1831 validadas pela equipe. As 550 linhas da Inquisição (CC BY 4.0), usadas no B, não trouxeram ganho. Cada treino leva de 3h30 a 6h30 numa GTX 1650 de 4 GB.

## O que cada integrante apresenta

Proposta de divisão pelas frentes do planejamento do artigo; a equipe ajusta. Cada um fala cerca de 2 minutos e meio, e cada fala termina passando a palavra para o próximo.

**1. Caio Augusto de Souza Soares: o problema e por que importa.** Abre a apresentação com uma página do Traslado na tela. Explica que o acervo de Jundiaí está digitalizado, mas sem transcrição, e que ler esses documentos exige paleografia (abreviaturas, grafias, formas de letra). Situa o trabalho na bibliografia: reconhecimento de manuscritos (HTR) com redes pré-treinadas e ajuste fino como adaptação de domínio. Fecha com o objetivo: uma ferramenta aberta em que o modelo sugere e o humano valida, com autorização do Arquivo para uso não comercial.

**2. Tiago Galhardo Avelar: os dados e como medimos.** Apresenta os documentos: Traslado de 1767 para treino, sessão de 1795 para validação, pagamento de 1759 e contrato de 1763 como teste reservado. Conta como o teste foi lido às cegas, com o reconhecedor desligado, e congelado com hash antes de qualquer avaliação; o código recusa esses documentos no treino. Explica CER e WER com um exemplo de uma linha (substituição, apagamento, inserção) e por que não usar só acurácia.

**3. Guilherme Rodrigues Veiga: o modelo e os resultados.** Mostra o fluxo técnico: segmentação blla, PP-OCRv6 medium em Docker, ajuste fino A (Traslado), B (+ Inquisição) e D1 (+ Posturas de 1831), um trecho do vídeo do treino na GPU. Apresenta a tabela de números: 58% → 15% na troca de modelo, 14,2% → 9,9% na validação, 64% → 55,4% no teste. Interpreta com honestidade: dados do próprio acervo ajudaram mais que os de fora (a Inquisição não mudou nada, as Posturas sim), mas o contrato de escrita densa continua difícil (66%).

**4. Rodolfo Vinicius Cima Takemoto: a aplicação ao vivo e a parte de PLN.** Faz a demonstração: abre um fólio das Posturas no modo leitura, valida uma linha com Enter, mostra o contexto de linhas vizinhas. Na aba Textos, alterna diplomática e modernizada,

mostra as palavras sublinhadas e uma nota do glossário. Resume o PLN: análise dos erros por tipo, pós-correção que piorou o CER e por quê, modernização v3 (WER 28% → 21% nas Posturas). Fecha com limitações e próximos passos.

## Perguntas prováveis do professor

Resposta curta primeiro; o detalhe só se ele pedir. Quem responde é quem apresentou o assunto.

| Pergunta | Resposta curta | Quem |
|---|---|---|
| Dá para confiar com só 7 linhas de validação? | Não no número exato: é desenvolvimento. Por isso o D1 também valida nas 31 linhas do fólio 101r, e o teste reservado (49 linhas, rodado uma vez por modelo) confirma o ganho | Tiago |
| Por que CER e WER e não acurácia? | São as métricas padrão de texto gerado: contam substituições, apagamentos e inserções, inclusive texto inventado, que a acurácia esconde | Tiago |
| Como garantem que o teste não vazou para o treino? | Escolhido antes de qualquer modelo, lido às cegas, congelado com hash; o código de treino recusa esses documentos; cada modelo roda nele uma vez | Tiago |
| Rodaram o teste mais de uma vez? | Cada modelo rodou uma vez só: base, A, B e D1. O D1 foi escolhido antes, no fólio 101r, sem olhar o teste. Com 4 modelos, a comparação entre eles não é mais totalmente cega, e isso está declarado | Tiago |
| Por que PP-OCRv6 e não TrOCR ou outro? | O TrOCR gerava texto sem sentido nessas páginas; o PP-OCRv6 é pré-treinado em manuscritos históricos e partiu de 15% de CER, contra 58% do v5 | Guilherme |

| Pergunta | Resposta curta | Quem |
|---|---|---|
| Por que o contrato vai tão mal (66%)? | Escrita densa, outra mão e muitas abreviaturas, sem nada parecido no treino. As Posturas já baixaram de 74% para 66%; o próximo passo é validar mais fólios do acervo | Guilherme |
| Os dados da Inquisição ajudaram? | Não dá para afirmar: B ficou 2 caracteres à frente de A na validação e meio ponto atrás no teste. Já as Posturas, do próprio acervo, ajudaram: o D1 passou o B no teste | Guilherme |
| Onde está o PLN no projeto? | Análise linguística dos erros, pós-correção lexical (Levenshtein × TF-IDF de n-gramas) e normalização ortográfica do português histórico (leitura modernizada) | Rodolfo |
| Por que a pós-correção piorou? | O vocabulário vem só do treino (para não contaminar a validação) e não cobre palavras corretas da validação; aí ela "corrige" o que estava certo | Rodolfo |
| A modernização é IA? Pode inventar? | São regras de grafia mais frequência de palavras numa lista pública; não gera texto livre. Nunca altera a diplomática e marca o que ficou duvidoso | Rodolfo |
| Qual o papel do humano? | Validar. Nenhuma sugestão vira transcrição sem conferência na imagem, e cada validação tem nome e histórico | Rodolfo |
| Podem usar as imagens do acervo? | Sim: são públicas no Acervo Digital da prefeitura, e o Arquivo autorizou o uso sem fins comerciais, com crédito | Caio |
| Usaram IA para fazer o projeto? | Sim, e está declarado na planilha de uso de IA e no artigo; as leituras e validações foram feitas pela equipe | Todos |
| E se o modelo errar e ninguém perceber? | A interface mostra a diferença entre a sugestão e a leitura, sublinha palavras fora do dicionário e mantém a saída bruta separada para auditoria | Rodolfo |

# Roteiro da apresentação

Roteiro de 10 minutos de fala e 5 de perguntas; a coluna da direita corta para 5 minutos, se esse for o limite.

| # | Quem | Parte | O que mostrar | 10 min | 5 min |
|---|---|---|---|---|---|
| 1 | Caio | Problema: acervo digitalizado e sem transcrição; paleografia é rara | Página do Traslado, com crédito ao Arquivo | 1:15 | 0:30 |
| 2 | Caio | Proposta: o modelo sugere, o humano valida; fundamentação | Slide com o fluxo em 7 passos | 1:15 | 0:30 |
| 3 | Tiago | Dados: treino, validação e teste reservado lido às cegas | Tabela dos documentos | 1:15 | 0:30 |
| 4 | Tiago | Como medimos: CER e WER com uma linha de exemplo | Linha do 269r: modelo × validada, erros sublinhados | 1:00 | 0:30 |
| 5 | Guilherme | Modelo: blla, PP-OCRv6, ajuste fino A, B e D1 | Print ou trecho do vídeo do treino | 1:00 | 0:30 |
| 6 | Guilherme | Resultados e interpretação | Tabela de números | 1:15 | 0:45 |
| 7 | Rodolfo | Demonstração ao vivo: modo leitura e aba Textos | Aplicativo aberto (iniciar_demo.bat) | 1:30 | 0:45 |
| 8 | Rodolfo | PLN: erros, pós-correção, modernização v3 | Gráfico de erros e tabela da modernização | 0:45 | 0:30 |
| 9 | Rodolfo | Limitações e próximos passos: poucas linhas, mãos diferentes, mais fólios do acervo e rótulos corrigidos | Lista curta | 0:45 | 0:30 |

### Antes do dia

- [ ] Combinar com o professor se são 5 ou 10 minutos de fala
- [ ] Abrir o app no notebook da apresentação e testar o modo leitura e a aba Textos
- [ ] Deixar prints da demonstração nos slides, como plano B se o app ou a rede falhar
- [ ] Ensaiar inteiro uma vez, cronometrado, com as passagens entre os quatro
- [ ] Cada um ler a tabela de perguntas da sua parte

**Frases de passagem:** Caio → Tiago: "Para saber se funciona, precisamos de dados confiáveis." Tiago → Guilherme: "Com isso definido, vamos ao modelo." Guilherme → Rodolfo: "Agora vamos ver isso funcionando."