PaleographIA: resumo e roteiro da apresentação

Nov 10, 2026 · @Rodolfo Vinicius Cima Takemoto.

Resumo do programa

O PaleographIA é uma ferramenta aberta e gratuita que ajuda a transcrever manuscritos dos séculos XVII a XIX do Arquivo Histórico de Jundiaí: o modelo sugere a leitura de cada linha e uma pessoa confere na imagem e valida.

O problema. O acervo de Jundiaí está digitalizado e público, mas quase nada está transcrito. Ler essas páginas exige formação em paleografia: abreviaturas, grafias antigas, letras que mudam de forma. Arquivos de cidades pequenas não têm paleógrafos para isso.

A ideia. A máquina não substitui o leitor: ela adianta o trabalho. Nenhuma sugestão vira transcrição sem conferência humana. Saída do modelo, sugestão e transcrição validada ficam sempre separadas, com o nome de quem validou e o histórico de cada mudança.

O caminho de uma página, do começo ao fim:

1. **Imagem.** A página do acervo entra no aplicativo (com crédito ao Arquivo, uso acadêmico e não comercial autorizado).
2. **Linhas.** O Kraken (segmentador blla, uma rede neural) desenha cada linha de texto e recorta a imagem dela.
3. **Leitura do modelo.** O PP-OCRv6 medium, ajustado com páginas de Jundiaí, lê cada recorte e propõe o texto.
4. **Revisão humana.** No modo leitura, o revisor vê o recorte ampliado, o contexto das linhas vizinhas e a sugestão; corrige e aperta Enter para validar.
5. **Texto diplomático.** As linhas validadas formam a transcrição paleográfica: como está escrito, sem atualizar nada.
6. **Leitura modernizada.** Por cima da diplomática, o programa gera uma versão em português atual para quem só quer ler ou buscar, com as palavras duvidosas sublinhadas e notas de um glossário histórico.
7. **Métricas.** CER e WER comparam a leitura do modelo com a validada e medem o quanto cada versão do modelo melhorou.

Como funciona por dentro

Cada parte do programa tem um papel e uma trava contra erro; vale saber explicar cada uma em uma frase.

Parte	O que faz	Por que importa
Aplicativo (FastAPI, no navegador)	Editor completo, **modo leitura** para revisar e aba **Textos** para ler o resultado	Cada validação grava uma revisão nova com nome do revisor; nada é sobrescrito
Segmentação (Kraken blla)	Encontra as linhas da página e junta pedaços cortados	Recorte ruim pode ser ajustado, juntado ou rejeitado pelo revisor
Reconhecimento (PP-OCRv6 medium)	Rede pré-treinada em manuscritos históricos, roda no Docker	Partiu de 15% de CER no Traslado, contra 58% do PP-OCRv5
Ajuste fino A e B	A: 191 linhas do Traslado. B: Traslado + 550 linhas públicas da Inquisição	Adaptação de domínio: o modelo aprende a letra e as grafias de Jundiaí
Ajustado C (próximo)	Traslado + 94 linhas das Posturas de 1831 validadas pela equipe	Pronto para treinar; antes, corrigir leituras que a edição do Arquivo apontou
Modo leitura	Recorte ampliado, setas para mover, contexto de 1 a 3 linhas acima e abaixo, Enter valida	Torna a revisão humana rápida, que é o gargalo real
Análise de erros (PLN)	Alinha leitura e referência por Levenshtein e classifica cada erro: espaço, pontuação, abreviatura, maiúscula, acento, grafia histórica, nome, forma da letra	Mostra o que o ajuste corrigiu (forma da letra, palavras coladas) e o que sobra (convenção de escrita)
Pós-correção lexical	Compara Levenshtein × TF-IDF de n-gramas de caracteres	Piorou o CER: o vocabulário de treino é pequeno. Fica só como sugestão ao revisor
Leitura modernizada v1 → v3	Regras de grafia antiga → atual escolhidas pela frequência no português atual; a v2 trata caixa, nomes e pretérito; a v3 trata artigo, réis, futuro, hífen e palavras grudadas	Nunca altera a diplomática. Avaliada contra a edição modernizada do Arquivo

Parte	O que faz	Por que importa
Palavras a conferir e glossário	Sublinha o que ficou fora do dicionário atual; notas [1][2][3] explicam palavras antigas (magotes, rocio)	Mostra ao pesquisador onde a leitura é duvidosa e leva à linha certa

A trava mais importante: o teste reservado. O pagamento a Thomas Pardo (1759) e um contrato de 1763 foram separados antes de qualquer treino, transcritos às cegas por dois integrantes com o reconhecedor desligado e congelados com hash. O código de treino recusa esses documentos, e cada modelo roda neles uma única vez. A validação, usada para escolher o melhor ponto do treino, são 7 linhas de uma sessão de 1795, de outra mão.

Números para citar

O ajuste fino baixa o erro em todas as medições, mas a generalização para mãos muito diferentes ainda é limitada. CER = erro por caractere, WER = erro por palavra; quanto menor, melhor.

Medição	Antes	Depois	Observação
Escolha do modelo: fólio 269r do Traslado (24 linhas)	PP-OCRv5: CER 58,5%	PP-OCRv6: CER 15,1%	Por isso o v6 foi adotado
Validação: sessão de 1795 (7 linhas, outra mão)	Base: CER 14,2%, WER 56,7%	A: 10,7% / 41,8%; B: 10,1% / 38,8%	B fica 2 caracteres à frente de A, dentro da variação
Teste reservado, uma vez (49 linhas, duas mãos)	Base: CER 64,0%	A: 60,5%; B: 60,9%	Cerca de 28% no pagamento (letra regular) e 74% no contrato (escrita densa)
Modernização no contrato, contra a edição do Arquivo	Sem modernizar: WER 44,7%	v2: WER 30,5%	Avaliação fechada antes de olhar o resultado
Modernização nas Posturas de 1831 (75 linhas)	v2: WER 28,3%	v3: WER 21,2%	Linhas de desenvolvimento da v3
Ajustado B nas Posturas (94 linhas validadas)	—	CER 16,8%, WER 52,7%	Leitura assistida: número otimista

Acurácia de caracteres ≈ 100% − CER: na validação, o B acerta cerca de 9 em cada 10 caracteres. Dados de treino: 191 linhas do Traslado (175 alinhadas à edição publicada + 16 lidas pela equipe) e 550 da Inquisição (CC BY 4.0). Treino B: 3h36 numa GTX 1650 de 4 GB.

O que cada integrante apresenta

Proposta de divisão pelas frentes do planejamento do artigo; a equipe ajusta. Cada um fala cerca de 2 minutos e meio, e cada fala termina passando a palavra para o próximo.

1. Caio Augusto de Souza Soares: o problema e por que importa. Abre a apresentação com uma página do Traslado na tela. Explica que o acervo de Jundiaí está digitalizado, mas sem transcrição, e que ler esses documentos exige paleografia (abreviaturas, grafias, formas de letra). Situa o trabalho na bibliografia: reconhecimento de manuscritos (HTR) com redes pré-treinadas e ajuste fino como adaptação de domínio. Fecha com o objetivo: uma ferramenta aberta em que o modelo sugere e o humano valida, com autorização do Arquivo para uso não comercial.

2. Tiago Galhardo Avelar: os dados e como medimos. Apresenta os documentos: Traslado de 1767 para treino, sessão de 1795 para validação, pagamento de 1759 e contrato de 1763 como teste reservado. Conta como o teste foi lido às cegas, com o reconhecedor desligado, e congelado com hash antes de qualquer avaliação; o código recusa esses documentos no treino. Explica CER e WER com um exemplo de uma linha (substituição, apagamento, inserção) e por que não usar só acurácia.

3. Guilherme Rodrigues Veiga: o modelo e os resultados. Mostra o fluxo técnico: segmentação blla, PP-OCRv6 medium em Docker, ajuste fino A (Traslado) e B (+ Inquisição), um trecho do vídeo do treino na GPU. Apresenta a tabela de números: 58% → 15% na troca de modelo, 14,2% → 10,1% na validação, 64% → 60,5% no teste. Interpreta com honestidade: o ganho existe, mas o contrato de escrita densa continua difícil (74%). Anuncia o ajustado C com as Posturas como próximo passo.

4. Rodolfo Vinicius Cima Takemoto: a aplicação ao vivo e a parte de PLN. Faz a demonstração: abre um fólio das Posturas no modo leitura, valida uma linha com Enter, mostra o contexto de linhas vizinhas. Na aba Textos, alterna diplomática e modernizada, mostra as palavras sublinhadas e uma nota do glossário. Resume o PLN: análise dos erros por tipo, pós-correção que piorou o CER e por quê, modernização v3 (WER 28% → 21% nas Posturas). Fecha com limitações e próximos passos.

Perguntas prováveis do professor

Resposta curta primeiro; o detalhe só se ele pedir. Quem responde é quem apresentou o assunto.

Pergunta	Resposta curta	Quem
Dá para confiar com só 7 linhas de validação?	Não no número exato: é desenvolvimento. O que é consistente é a direção, e o teste reservado (49 linhas, rodado uma vez) confirma o ganho	Tiago
Por que CER e WER e não acurácia?	São as métricas padrão de texto gerado: contam substituições, apagamentos e inserções, inclusive texto inventado, que a acurácia esconde	Tiago
Como garantem que o teste não vazou para o treino?	Escolhido antes de qualquer modelo, lido às cegas, congelado com hash; o código de treino recusa esses documentos; cada modelo roda nele uma vez	Tiago
Por que PP-OCRv6 e não TrOCR ou outro?	O TrOCR gerava texto sem sentido nessas páginas; o PP-OCRv6 é pré-treinado em manuscritos históricos e partiu de 15% de CER, contra 58% do v5	Guilherme
Por que o contrato vai tão mal (74%)?	Escrita densa, outra mão e muitas abreviaturas, sem nada parecido no treino. Por isso o ajustado C traz documentos novos	Guilherme
Os dados da Inquisição ajudaram?	Não dá para afirmar: B ficou 2 caracteres à frente de A na validação e meio ponto atrás no teste, dentro da variação	Guilherme
Onde está o PLN no projeto?	Análise linguística dos erros, pós-correção lexical (Levenshtein × TF-IDF de n-gramas) e normalização ortográfica do português histórico (leitura modernizada)	Rodolfo
Por que a pós-correção piorou?	O vocabulário vem só do treino (para não contaminar a validação) e não cobre palavras corretas da validação; aí ela "corrige" o que estava certo	Rodolfo

Pergunta	Resposta curta	Quem
A modernização é IA? Pode inventar?	São regras de grafia mais frequência de palavras numa lista pública; não gera texto livre. Nunca altera a diplomática e marca o que ficou duvidoso	Rodolfo
Qual o papel do humano?	Validar. Nenhuma sugestão vira transcrição sem conferência na imagem, e cada validação tem nome e histórico	Rodolfo
Podem usar as imagens do acervo?	Sim: são públicas no Acervo Digital da prefeitura, e o Arquivo autorizou o uso sem fins comerciais, com crédito	Caio
Usaram IA para fazer o projeto?	Sim, e está declarado na planilha de uso de IA e no artigo; as leituras e validações foram feitas pela equipe	Todos
E se o modelo errar e ninguém perceber?	A interface mostra a diferença entre a sugestão e a leitura, sublinha palavras fora do dicionário e mantém a saída bruta separada para auditoria	Rodolfo

Roteiro da apresentação

Roteiro de 10 minutos de fala e 5 de perguntas; a coluna da direita corta para 5 minutos, se esse for o limite.

#	Quem	Parte	O que mostrar	10 min	5 min
1	Caio	Problema: acervo digitalizado e sem transcrição; paleografia é rara	Página do Traslado, com crédito ao Arquivo	1:15	0:30
2	Caio	Proposta: o modelo sugere, o humano valida; fundamentação	Slide com o fluxo em 7 passos	1:15	0:30
3	Tiago	Dados: treino, validação e teste reservado lido às cegas	Tabela dos documentos	1:15	0:30
4	Tiago	Como medimos: CER e WER com uma linha de exemplo	Linha do 269r: modelo × validada, erros sublinhados	1:00	0:30
5	Guilherme	Modelo: blla, PP-OCRv6, ajuste fino A e B	Print ou trecho do vídeo do treino	1:00	0:30

#	Quem	Parte	O que mostrar	10 min	5 min
6	Guilherme	Resultados e interpretação	Tabela de números	1:15	0:45
7	Rodolfo	Demonstração ao vivo: modo leitura e aba Textos	Aplicativo aberto (iniciar_demo.bat)	1:30	0:45
8	Rodolfo	PLN: erros, pós-correção, modernização v3	Gráfico de erros e tabela da modernização	0:45	0:30
9	Rodolfo	Limitações e próximos passos: poucas linhas, mãos diferentes, ajustado C	Lista curta	0:45	0:30

Antes do dia

- [ ] Combinar com o professor se são 5 ou 10 minutos de fala
- [ ] Abrir o app no notebook da apresentação e testar o modo leitura e a aba Textos
- [ ] Deixar prints da demonstração nos slides, como plano B se o app ou a rede falhar
- [ ] Ensaiar inteiro uma vez, cronometrado, com as passagens entre os quatro
- [ ] Cada um ler a tabela de perguntas da sua parte

Frases de passagem: Caio → Tiago: "Para saber se funciona, precisamos de dados confiáveis." Tiago → Guilherme: "Com isso definido, vamos ao modelo." Guilherme → Rodolfo: "Agora vamos ver isso funcionando."